

***Universidad Tecnológica
de El Salvador***



Escuela de informática y ciencias aplicada.

Docente: ING Jorge machado

Materia: Electiva II

Actividad: Ejercicio Práctico.

Alumno: Miguel jose pino Cortez.

Carnet: 17-0147-2022

Fecha 9/05/2026.

Contenido

Introducción.	3
Objetivo.....	4
Descripción del dataset.....	5
Preparación de datos en Python.	6
Análisis de Correlación e Interpretación	6
Análisis del Modelo de 4 Clústeres	7
Hallazgos principales.	7

Introducción.

En esta industria moderna de producción de software, la competencia de una organización no depende solo de la calidad de su código, si no de la capacidad para gestionar el talento humano. **InnovaSoft Analytics**, una empresa líder en el sector, se enfrenta al reto de organizar sus equipos de trabajo de manera eficiente, optimizando la formación y la especialización de sus colaboradores.

En este informe detallamos la aplicación de técnica de minería de datos, con un algoritmo de aprendizaje no supervisado K-Means (Clusterización) y a través de este análisis buscamos definir patrones y agrupaciones naturales dentro de datos de la organización y también esto se basa en toma de decisiones basada en los datos, creando facilidad en la hora de creación de planes de carrera personalizados y optimización de procesos de producción de software mediante la correcta asignaciones

Objetivo

General:

Analizar la relación entre educación, ingresos y prestigio en diversos perfiles para optimizar la valoración de roles técnicos y gerenciales en la producción de software.

Específicos:

- Determinar qué factores socioeconómicos influyen más en el prestigio de una ocupación.
- Segmentar los perfiles mediante clusterización para identificar grupos de especialización y niveles de responsabilidad.
- Proponer recomendaciones estratégicas basadas en datos para la gestión de talento.

Descripción del dataset.

también se trabajó con el archivo Prestige_modificado.csv, el cual funciona como base para practicar técnicas de análisis trasladables a la producción industrial de software.

- **Variables Clave:** education (nivel educativo), income (ingresos), women (participación femenina), prestige (valoración social) y type_num (tipo de ocupación codificado).
- **Contexto:** Los datos permiten comprender la relación entre la formación académica y la valoración del trabajo dentro de una organización.

Preparación de datos en Python.

Siguiendo los estándares de calidad de datos, se ejecutó lo siguiente:

- **Inspección:** Se validó que el dataset cuenta con 102 registros y 7 columnas.
- **Calidad:** Se confirmó la ausencia de valores nulos y duplicados, garantizando un dataset limpio para el modelado.
- **Transformación:** Se seleccionaron las variables numéricas y se aplicó un escalamiento (StandardScaler) para normalizar las magnitudes de ingresos y educación, paso fundamental para algoritmos basados en distancias

Análisis de Correlación e Interpretación

El análisis revela qué factores impulsan el prestigio de una ocupación:

- **Educación (0.85):** Es la variable con la correlación positiva más fuerte; a mayor nivel educativo, mayor es el prestigio percibido.
- **Ingresos (0.71):** Presenta una relación sólida, aunque menor que la educación, sugiriendo que el estatus profesional no depende únicamente del salario.
- **Mujeres (-0.12):** Muestra una relación negativa muy débil, indicando que la presencia de mujeres no define el nivel de prestigio de los roles en este dataset.

Análisis del Modelo de 4 Clústeres

- **Clúster 0:** Se caracteriza por un alto nivel de educación y prestigio, con ingresos intermedios y una participación de mujeres moderada. Este grupo podría representar roles técnicos o profesionales bien establecidos.
- **Clúster 1:** Tiene niveles de educación, ingreso y prestigio más bajos, con una baja participación de mujeres. Podría corresponder a ocupaciones de soporte o "blue collar" con menor cualificación.
- **Clúster 2:** Se distingue por una alta participación de mujeres, con educación, ingreso y prestigio bajos. Este grupo podría indicar ocupaciones con una feminización importante y menor valoración social.
- **Clúster 3:** Presenta los valores más altos en educación, ingreso y prestigio, con una muy baja participación de mujeres. Posiblemente represente roles gerenciales o de alta especialización, muy valorados y tradicionalmente masculinizados.

Hallazgos principales.

- En los roles con mayor educación tienden a concentrar el prestigio y los ingresos validando las necesidades de los planes de formación continua.
- Tenemos una clara segmentación por tipo de ocupación; los roles de las operaciones en termino de valoración social.

Conclusiones y Recomendaciones

- **Decisión de Talento:** InnovaSoft debe priorizar la formación en áreas de alta especialización, ya que la educación es el motor principal de la valoración del rol.
- **Mejora de Procesos:** Los grupos identificados con bajo prestigio y educación deben ser evaluados para procesos de industrialización o automatización para mejorar su eficiencia operativa.
- **La Educación como Activo Estratégico:** El análisis de correlación (0.85) confirma que el nivel educativo es el motor principal de la valoración profesional. En un entorno de producción industrial de software, esto significa que la empresa no solo debe contratar por habilidades técnicas inmediatas, sino valorar la formación académica base, ya que esta correlaciona directamente con la capacidad de asumir roles de mayor prestigio y complejidad.
- **Identificación de Brechas de Género:** Se observa una tendencia donde los grupos con mayores ingresos y prestigio (Clústeres 3 y 4) presentan la menor participación de mujeres. Esto representa un hallazgo crítico para el departamento de Recursos Humanos, indicando una posible "barrera de cristal" en las posiciones de liderazgo técnico o arquitectónico.

Anexos con capturas o código relevante.

Diccionario de Variables Utilizadas

Para facilitar la interpretación gerencial de los anexos, se detalla el significado de cada campo en el modelo:

- **Education:** Nivel educativo promedio asociado a la ocupación.
- **Income:** Ingreso promedio anual asociado al rol.
- **Women:** Porcentaje de participación femenina en la posición.
- **Prestige:** Índice de valoración social del trabajo.
- **Type_num:** Clasificación del tipo de ocupación (1: Profesional/Técnico, 2: Blue collar, 3: White collar).

Evidencias del Proceso de Calidad

- **Ausencia de Nulos:** Se confirmó que el dataset está completo al 100%, eliminando riesgos de sesgo en el cálculo de distancias euclidianas del modelo K-Means.
- **Escalamiento:** Se aplicó StandardScaler para evitar que variables con escalas grandes (como income) dominaran injustamente sobre variables con escalas pequeñas (como education), garantizando la equidad matemática del modelo.

```
In [ ]: "Análisis de agrupación de ocupaciones"
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans

columnas_cluster = ['education', 'income', 'women', 'prestige', 'type_num']
X = df[columnas_cluster].copy()

escalador = StandardScaler()
X_escalado = escalador.fit_transform(X)

modelo_k4 = KMeans(n_clusters=4, random_state=42, n_init=10)
df['Cluster_4'] = modelo_k4.fit_predict(X_escalado)

modelo_k5 = KMeans(n_clusters=5, random_state=42, n_init=10)
df['Cluster_5'] = modelo_k5.fit_predict(X_escalado)

print(df.groupby('Cluster_4')[columnas_cluster].mean().round(2))
print(df.groupby('Cluster_5')[columnas_cluster].mean().round(2))
```

	education	income	women	prestige	type_num
Cluster_4					
0	13.59	7329.35	36.35	63.33	0.95
1	8.82	5878.74	9.60	37.26	2.09
2	10.12	3545.04	74.16	37.76	2.57
3	14.69	15746.83	6.00	74.23	1.00
Cluster_5					
0	10.94	3909.12	73.76	41.50	2.88
1	9.31	6922.03	5.84	42.18	2.25
2	13.59	7329.35	36.35	63.33	0.95
3	7.78	3327.48	34.10	26.87	1.71
4	14.69	15746.83	6.00	74.23	1.00

